



班级: 计14 姓名: 汪隽立 编号: 2021012957 科目: 机器学习 第 1 页

2.1. $\epsilon(\hat{r}) > \epsilon \iff P[C_r \setminus C_{\hat{r}}] > \epsilon$ (误差只出现在 C_r 以内)

$\iff C_r \subset C_{r'} \text{ (几何视角)} \iff \hat{r} < r'$

2.2. 由 2.1. $P_{D_n}[\epsilon(\hat{r}_{D_n}) > \epsilon] = P_{D_n}[\hat{r} < r'] = P_{D_n}[D_n \text{ 中每一个正例都在 } C_{r'} \text{ 内}]$.

而 $P_{D_n}[\text{每一个正例都在 } C_{r'} \text{ 内}] \leq (1 - \epsilon)^n$

故 $P_{D_n}[\epsilon(\hat{r}_{D_n}) > \epsilon] \leq (1 - \epsilon)^n \leq \exp(-n\epsilon)$

□

2.3. 易知 $\epsilon(r) = 0$. 由 2.2. 只要 $n > \frac{1}{\epsilon} \log \frac{1}{\delta}$, 就有 $P[\epsilon(\hat{r}_{D_n}) - \epsilon(r) < \epsilon] < \delta$.
而 $\frac{1}{\epsilon} \log \frac{1}{\delta}$ 是 $O(\text{poly}(\frac{1}{\epsilon}, \frac{1}{\delta}))$. 故该问题是 PAC-Learnable 的. □

2.4. $\epsilon(r) = P[C_r] \cdot \eta$

$\epsilon(r') = (P[C_r] - \epsilon) \eta + \epsilon(1 - \eta) = P[C_r] \cdot \eta + \epsilon(1 - 2\eta)$

2.5. 由 2.4 知, 因为 $1 - 2\eta > 0$. 故 $\epsilon(r')$ 关于 ϵ 单调增. 也就是说, 学到的半径越小的 $C_{\hat{r}}$, 期望误差越大.

现在固定 $\epsilon > 0$, 令 r'' 是使得 $P[C_r \setminus C_{r'']} = \frac{\epsilon}{1 - 2\eta}$ (不妨假设 $P[C_r] > \frac{\epsilon}{1 - 2\eta}$, 不然, 对于这个 ϵ , 一定有 $\epsilon(\hat{r}) - \epsilon(r) \leq P[C_r] \cdot (1 - 2\eta) \leq \epsilon$, 自然满足 PAC-可学的条件).

由上分析可知 $\epsilon(\hat{r}) - \epsilon(r) < \epsilon \iff \hat{r} < r''$

故 $P[\epsilon(\hat{r}) - \epsilon(r) < \epsilon] = P[\hat{r} < r''] \leq (1 - \frac{\epsilon}{1 - 2\eta})^n \leq (1 - \frac{\epsilon}{1 - 2\eta})^n$

$\leq \exp(\frac{-n\epsilon}{1 - 2\eta})$. 故只要 $n > \frac{1}{\epsilon} \log \frac{1}{\delta} \cdot (1 - 2\eta)$, 就有 $P[\epsilon(\hat{r}) - \epsilon(r) < \epsilon] < \delta$.

这也满足 PAC-Learnable 的条件.

□

$$3.1. \quad \mathcal{L}_{D_i}(f_i) = \sum_{(x,y)} P_{D_i}(x,y) \cdot \mathbb{1}[y \neq f_i(x)] = 0$$

$$3.2. \quad \max_{1 \leq i \leq T} \mathbb{E}_{D_n^{(i)}} [\mathcal{L}_{D_i}(A(D_n^{(i)}))] \\ \geq \frac{1}{T} \sum_{i=1}^T \mathbb{E}_{D_n^{(i)}} [\mathcal{L}_{D_i}(A(D_n^{(i)}))] \quad (\max \geq \text{avg}) \\ \geq \frac{1}{T} \sum_{i=1}^T \min_{D_n^{(i)}} \mathcal{L}_{D_i}(A(D_n^{(i)})) \quad (\text{avg} \geq \min)$$

而因为 $\{D_n^{(i)}\} \subset \{S_j^{(i)}\}_{j=1}^k$, (这里 $T = 2^{2n}$, $k = (2n)^n$) (也就是说从 $\{S_j^{(i)}\}_{j=1}^k$ 里选最小的, 至少能选到与 $\{D_n^{(i)}\}$ 中最小的一个一样小的)

$$\text{故 } \frac{1}{T} \sum_{i=1}^T \min_{D_n^{(i)}} \mathcal{L}_{D_i}(A(D_n^{(i)})) \geq \frac{1}{T} \sum_{i=1}^T \min_{S_j^{(i)}} \mathcal{L}_{D_i}(A(S_j^{(i)})) \\ = \frac{1}{T} \sum_{i=1}^T \min_{1 \leq j \leq k} \mathcal{L}_{D_i}(A(S_j^{(i)}))$$

$$3.3. \quad \text{先证明 } \mathcal{L}_{D_i}(h) \geq \frac{1}{2p} \sum_{r=1}^p \mathbb{1}[h(v_r) \neq f_i(v_r)], \text{ where } h = A(S_j^{(i)}).$$

proof: $\mathcal{L}_{D_i}(h) = \frac{1}{2n} \sum_{j=1}^{2n} \mathbb{1}[h(x_j) \neq f_i(x_j)] \\ \geq \frac{1}{2n} \sum_{r=1}^p \mathbb{1}[h(v_r) \neq f_i(v_r)] \geq \frac{1}{2p} \sum_{r=1}^p \mathbb{1}[h(v_r) \neq f_i(v_r)] \quad (p \geq n)$

然后证明原命题. 两边对 i 从 1 到 T 求和有 (然后取平均):

$$\frac{1}{T} \sum_{i=1}^T \mathcal{L}_{D_i}(A(S_j^{(i)})) \geq \frac{1}{2pT} \sum_{i=1}^T \sum_{r=1}^p \mathbb{1}[h(v_r) \neq f_i(v_r)] = \frac{1}{2pT} \sum_{r=1}^p \sum_{i=1}^T \mathbb{1}[h(v_r) \neq f_i(v_r)]$$

$$3.4. \quad \max_{1 \leq i \leq T} \mathbb{E}_{D_n^{(i)}} [\mathcal{L}_{D_i}(A(D_n^{(i)}))] \geq \frac{1}{T} \sum_{i=1}^T \min_{1 \leq j \leq k} \mathcal{L}_{D_i}(A(S_j^{(i)})) \geq \frac{1}{2pT} \sum_{i=1}^T \sum_{r=1}^p \mathbb{1}[h(v_r) \neq f_i(v_r)] \quad (*)$$

因为 f_i 和 $f_{i'}$ 在 S_j 上的标签完全相同, 故 $S_j^{(i)} = S_j^{(i')}$. 又算法返回的 h 只由 $S_j^{(i)}$ 决定, 故

$$\mathbb{1}[A(S_j^{(i)})(v_r) \neq f_i(v_r)] + \mathbb{1}[A(S_j^{(i')})(v_r) \neq f_{i'}(v_r)] = 1. \quad \text{for any } r \in [1, p]$$

(这是说, 对于 v_1, \dots, v_p 中任意一个点, $A(S_j^{(i)})$ 和 $A(S_j^{(i')})$ 总有一个将其分类正确, 另一个分类错误)

$$\text{故 } \frac{1}{2pT} \sum_{r=1}^p \sum_{i=1}^T \mathbb{1}[h(v_r) \neq f_i(v_r)] = \frac{1}{2pT} \sum_{r=1}^p \frac{T}{2} = \frac{1}{4}. \quad (\text{一共分成了 } \frac{T}{2} \text{ 个 } (i, i') \text{ 组})$$

代入 (*) 式即证



3.5 由3.4, 我们有 $\max_{1 \leq i \leq 7} \mathbb{E}[\mathcal{L}(A(D_n^{(i)}))] \geq \frac{1}{4}$. 不妨设取到max的下标为*i*, 即

$$\begin{aligned} \mathbb{E}_{D_n^{(i)}}[\mathcal{L}(A(D_n^{(i)}))] &\geq \frac{1}{4}. \text{ 因为 } \mathcal{L}(A(D_n^{(i)})) \in [0, 1], \text{ 故 } P_{D_n^{(i)}}[\mathcal{L}(A(D_n^{(i)})) > \frac{1}{8}] \\ &= \frac{\mathbb{E}_{D_n^{(i)}}[\mathcal{L}(A(D_n^{(i)}))] - \frac{1}{8}}{\frac{1}{8}} \geq \frac{1}{7}. \text{ (在Lemma中令 } a = \frac{1}{8}) \end{aligned}$$

也就是说, 总存在一个分布 $D^{(i)}$, 对于 $D_n^{(i)}$ 的选择, 有至少 $\frac{1}{7}$ 的概率使得 $\mathcal{L}(A(D_n^{(i)})) \geq \frac{1}{8}$

3.6. 假设该概念类是可学习的, 那么对于 \mathcal{X} 上的任意分布 D , 任意的标签函数 f , 对于任意的 $\varepsilon > 0, \delta > 0$. 只要 $n > \text{poly}(\frac{1}{\varepsilon}, \frac{1}{\delta})$, 就有 $P(\mathcal{L}(A(D_n)) > \varepsilon) < \delta$.
然而由 $\hat{\text{No-Free-Lunch Thm.}}$, 因为 $\frac{|\mathcal{X}|}{2} > n$. 故总能找到一个分布 D 和一个标签函数 f ,
使得 $P(\mathcal{L}(A(D_n)) > \frac{1}{8}) > \frac{1}{7}$. 这与 ε, δ 的任意性矛盾. \square

$$4.1 \quad P(\exists i, 1 \leq i \leq k, \|\hat{P}_i - P_i\|_1 > \varepsilon)$$

$$\begin{aligned} &= P(\|\hat{P}_1 - P_1\|_1 > \varepsilon \vee \dots \vee \|\hat{P}_k - P_k\|_1 > \varepsilon) \\ &\leq \sum_{i=1}^k P(\|\hat{P}_i - P_i\|_1 > \varepsilon) \quad (\text{Union Bound}) \end{aligned}$$

而对于 $\forall i, 1 \leq i \leq k$, 有

$$P(\|\hat{P}_i - P_i\|_1 > \varepsilon) \leq P(|\hat{P}_{i,1} - P_{i,1}| > \frac{\varepsilon}{m} \vee |\hat{P}_{i,2} - P_{i,2}| > \frac{\varepsilon}{m} \vee \dots \vee |\hat{P}_{i,m} - P_{i,m}| > \frac{\varepsilon}{m})$$

(至少有一项要大于 $\frac{\varepsilon}{m}$)

$$\leq \sum_{j=1}^m P(|\hat{P}_{i,j} - P_{i,j}| > \frac{\varepsilon}{m}) \quad (\text{Union Bound})$$

$$= \sum_{j=1}^m P\left(\left|\frac{1}{n} \sum_{s=1}^n \mathbf{1}[X_i^{(s)} = j] - \mathbb{E}[\mathbf{1}[X_i^{(s)} = j]]\right| > \frac{\varepsilon}{m}\right)$$

$$\leq \sum_{j=1}^m 2e^{-\frac{2n\varepsilon^2}{m^2}} \quad (\text{Hoeffding's ineq.})$$

$$= 2me^{-\frac{2n\varepsilon^2}{m^2}}. \quad \text{故 } P(\exists i, 1 \leq i \leq k, \|\hat{P}_i - P_i\|_1 > \varepsilon) \leq 2mke^{-\frac{2n\varepsilon^2}{m^2}}.$$

令 $2mk e^{-\frac{2ne^2}{m^2}} = \delta$. 得 $\epsilon = m \sqrt{\frac{1}{2n} \log \frac{2mk}{\delta}}$.

即 $\exists i$, s.t. $\|\hat{P}_i - P_i\|_1 > m \sqrt{\frac{1}{2n} \log \frac{2mk}{\delta}}$ 的概率不超过 δ

即 $\forall i$, $\|\hat{P}_i - P_i\|_1 \leq m \sqrt{\frac{1}{2n} \log \frac{2mk}{\delta}}$ 的概率至少为 $1 - \delta$

□

4.2. 我们直接 Bound $P(\|\hat{P}_i - P_i\|_1 > \epsilon)$

$$\begin{aligned} P(\|\hat{P}_i - P_i\|_1 > \epsilon) &= P\left(\sup_{u \in \{1, \dots, m\}} u^T (\hat{P}_i - P_i) > \epsilon\right) = P(u_1^T (\hat{P}_i - P_i) > \epsilon \vee u_2^T (\hat{P}_i - P_i) > \epsilon \vee \dots) \\ &\leq \sum_{r=1}^m P(u_r^T (\hat{P}_i - P_i) > \epsilon) \quad (\text{Union Bound}) \\ &= \sum_{r=1}^m P\left(\sum_{j=1}^m u_{r,j} (\hat{P}_{i,j} - \mathbb{E}[\hat{P}_{i,j}]) > \epsilon\right) = \sum_{r=1}^m P\left(\sum_{j=1}^m u_{r,j} \left(\sum_{s=1}^n \frac{1}{n} \mathbb{1}[X_i^{(s)} = j] - \mathbb{E}[\mathbb{1}[X_i^{(s)} = j]]\right) > \epsilon\right) \\ &= \sum_{r=1}^m P\left(\frac{1}{n} \sum_{s=1}^n \sum_{j=1}^m u_{r,j} \mathbb{1}[X_i^{(s)} = j] - \sum_{j=1}^m u_{r,j} \mathbb{E}[\mathbb{1}[X_i^{(s)} = j]] > \epsilon\right) \quad (\text{交换求和顺序}) \\ &= \sum_{r=1}^m P\left(\frac{1}{n} \sum_{s=1}^n \left(\sum_{j=1}^m u_{r,j} \mathbb{1}[X_i^{(s)} = j]\right) - \mathbb{E}\left[\sum_{j=1}^m u_{r,j} \mathbb{1}[X_i^{(s)} = j]\right] > \epsilon\right) \quad (\text{期望线性性}) \end{aligned}$$

记 $Y_s = \sum_{j=1}^m u_{r,j} \mathbb{1}[X_i^{(s)} = j]$. $Y_s \in [-1, +1]$.

$$= \sum_{r=1}^m P\left(\frac{1}{n} \sum_{s=1}^n Y_s - \mathbb{E}[Y_s] > \epsilon\right) \leq \sum_{r=1}^m e^{\frac{-2n\epsilon^2}{4}} \stackrel{\text{Hoeffding's ineq.}}{=} \sum_{r=1}^m e^{-\frac{n\epsilon^2}{2}} = 2^m e^{-\frac{n\epsilon^2}{2}}.$$

故 $P(\exists i, 1 \leq i \leq k, \|\hat{P}_i - P_i\|_1 > \epsilon) \leq k \cdot 2^m \cdot e^{-\frac{n\epsilon^2}{2}}$

令 $k \cdot 2^m \cdot e^{-\frac{n\epsilon^2}{2}} = \delta$ 即得结果!

□



班级: 计14

姓名: 汪佳立

编号: 2021012957

科目: 机器学习

第 5 页


5. Hoeffding's Ineq. 给出的界为:

$$P(\hat{\epsilon}(h) - \epsilon(h) > \epsilon) \leq 2e^{-2n\epsilon^2} \quad \text{令 } 2e^{-2n\epsilon^2} = \delta \cdot p(h) \text{ 得 } \epsilon = \sqrt{\frac{\log \frac{1}{p(h)} + \log \frac{1}{\delta}}{2n}}$$

(For a certain h)也即对于任意一个(确定的) $h \in H$, 至少以 $1 - \delta p(h)$ 的概率成立 $\hat{\epsilon}(h) - \epsilon(h) \leq \sqrt{\frac{\log \frac{1}{p(h)} + \log \frac{1}{\delta}}{2n}}$ 也即对于某一个 $h \in H$, 至多有 $\delta p(h)$ 的概率成立 $\epsilon(h) - \hat{\epsilon}(h) > \sqrt{\frac{\log \frac{1}{p(h)} + \log \frac{1}{\delta}}{2n}}$ 故至多有 $\sum_h \delta p(h) = \delta$ 的概率,成立 $\exists h \in H, \hat{\epsilon}(h) - \epsilon(h) > \sqrt{\frac{\log \frac{1}{p(h)} + \log \frac{1}{\delta}}{2n}}$ (Union Bound)也即至少有 $1 - \delta$ 的概率, 对于 $\forall h \in H, \hat{\epsilon}(h) - \epsilon(h) \leq \sqrt{\frac{\log \frac{1}{p(h)} + \log \frac{1}{\delta}}{2n}}$ \square

与课件上给出的误差界进行比较:

1. 首先, 二者都是误差界的多假设情况.

即以 $1 - \delta$ 的概率一致地成立 $\hat{\epsilon}(h) \leq \epsilon(h) + \sqrt{\frac{\log \frac{1}{p(h)} + \log \frac{1}{\delta}}{2n}}$
(对任意 $h \in H$)

$$P(\text{阴影}) \geq 1 - \delta[p(h_1) + \dots + p(h_m)] = 1 - \delta$$

2. 其次, 二者的 bounding 一个与 h 本身的性质(测度)无关,一个则与 $p(h)$ 有关. 也即虽然 bound 是一致成立的, 但每个 h 的 bound 不同, 在这道习题给出的结果里3. 如果在此中每个 h 的测度都是一样的(即 $\frac{1}{|H|}$), 那么二者是一样的.可以将课件上结果看作本这结果中, 每个 h 被选择概率一样的例子

6.1. 先证明经验 Rademacher 复杂度的下述性质

1. 若 $\mathcal{H} \subseteq \mathcal{H}'$, 则 $\hat{R}_{S_n}(\mathcal{H}) \leq \hat{R}_{S_n}(\mathcal{H}')$

$$\text{proof: } \hat{R}_{S_n}(\mathcal{H}) = \mathbb{E}_{\sigma} \left[\sup_{h \in \mathcal{H}} \frac{1}{n} \sum_{i=1}^n \sigma_i h(x_i) \right] \leq \mathbb{E}_{\sigma} \left[\sup_{h \in \mathcal{H}'} \frac{1}{n} \sum_{i=1}^n \sigma_i h(x_i) \right] = \hat{R}_{S_n}(\mathcal{H}')$$

2. $\hat{R}_{S_n}(\alpha \mathcal{H}) = |\alpha| \hat{R}_{S_n}(\mathcal{H})$, 其中 $\alpha \mathcal{H} = \{\alpha h \mid \forall h \in \mathcal{H}\}$

$$\begin{aligned} \text{proof: } \hat{R}_{S_n}(\alpha \mathcal{H}) &= \mathbb{E}_{\sigma} \left[\sup_{h \in \mathcal{H}} \frac{1}{n} \sum_{i=1}^n \sigma_i h(x_i) \right] = \mathbb{E}_{\sigma} \left[\sup_{h \in \mathcal{H}} \frac{\alpha}{n} \sum_{i=1}^n \sigma_i h(x_i) \right] \\ &= \begin{cases} \mathbb{E}_{\sigma} \left[\alpha \sup_{h \in \mathcal{H}} \frac{1}{n} \sum_{i=1}^n \sigma_i h(x_i) \right], & \alpha \geq 0 \\ \mathbb{E}_{\sigma} \left[\alpha \inf_{h \in \mathcal{H}} \frac{1}{n} \sum_{i=1}^n \sigma_i h(x_i) \right], & \alpha < 0 \end{cases} \end{aligned}$$

$$\text{而由 } \sigma \text{ 的对称性, } \mathbb{E}_{\sigma} \left[\inf_{h \in \mathcal{H}} \frac{1}{n} \sum_{i=1}^n \sigma_i h(x_i) \right] = -\mathbb{E}_{\sigma} \left[\sup_{h \in \mathcal{H}} \frac{1}{n} \sum_{i=1}^n \sigma_i h(x_i) \right]$$

(对于某个 σ , 当找到了某个 $h \in \mathcal{H}$ s.t. $\sum \sigma_i h(x_i)$ 最小时, 其恰好也是使 $\sigma' = -\sigma$ 时, $\sum \sigma'_i h(x_i)$ 最大的那个 h , 而且这时 $\sum \sigma_i h(x_i) = -\sum \sigma'_i h(x_i)$)

$$\text{故 } \hat{R}_{S_n}(\alpha \mathcal{H}) = |\alpha| \mathbb{E}_{\sigma} \left[\sup_{h \in \mathcal{H}} \frac{1}{n} \sum_{i=1}^n \sigma_i h(x_i) \right] = |\alpha| \hat{R}_{S_n}(\mathcal{H})$$

3. $\hat{R}_{S_n}(\mathcal{H} + \mathcal{H}') \leq \hat{R}_{S_n}(\mathcal{H}) + \hat{R}_{S_n}(\mathcal{H}')$. 其中 $\mathcal{H} + \mathcal{H}' = \{h + h' \mid \forall h \in \mathcal{H}, \forall h' \in \mathcal{H}'\}$

$$\text{proof: } \hat{R}_{S_n}(\mathcal{H} + \mathcal{H}') = \mathbb{E}_{\sigma} \left[\sup_{g \in \mathcal{H} + \mathcal{H}'} \frac{1}{n} \sum_{i=1}^n \sigma_i g(x_i) \right], \text{ where } g = h + h'$$

$$\begin{aligned} &= \mathbb{E}_{\sigma} \left[\sup_{g \in \mathcal{H} + \mathcal{H}'} \frac{1}{n} \sum_{i=1}^n \sigma_i h(x_i) + \frac{1}{n} \sum_{i=1}^n \sigma_i h'(x_i) \right] \\ &\leq \mathbb{E}_{\sigma} \left[\sup_{g \in \mathcal{H} + \mathcal{H}'} \frac{1}{n} \sum_{i=1}^n \sigma_i h(x_i) \right] + \mathbb{E}_{\sigma} \left[\sup_{g \in \mathcal{H} + \mathcal{H}'} \frac{1}{n} \sum_{i=1}^n \sigma_i h'(x_i) \right] \quad (\text{sup 的半可加性}) \\ &= \mathbb{E}_{\sigma} \left[\sup_{h \in \mathcal{H}} \frac{1}{n} \sum_{i=1}^n \sigma_i h(x_i) \right] + \mathbb{E}_{\sigma} \left[\sup_{h' \in \mathcal{H}'} \frac{1}{n} \sum_{i=1}^n \sigma_i h'(x_i) \right] \\ &= \hat{R}_{S_n}(\mathcal{H}) + \hat{R}_{S_n}(\mathcal{H}') \end{aligned}$$



$$4. \hat{R}_{S_n}(\text{convex-hull}(\mathcal{H})) = \hat{R}_{S_n}(\mathcal{H})$$

$$\text{proof: } \hat{R}_{S_n}(\text{convex-hull}(\mathcal{H})) = \mathbb{E} \left[\sup_{\sigma} \frac{1}{n} \sum_{i=1}^n \sigma_i h_i(x_i) \right] = \mathbb{E} \left[\sup_{\substack{\sum \lambda_j h_j \in \\ \text{convex-hull}(\mathcal{H})}} \frac{1}{n} \sum_{i=1}^n \sigma_i \sum_{j=1}^k \lambda_j h_j(x_i) \right]$$

$$= \mathbb{E} \left[\sum_{j=1}^k \sup_{\sigma} \frac{1}{n} \sum_{i=1}^n \sigma_i \lambda_j h_j(x_i) \right] \quad (\sum \text{取最大} \Leftrightarrow \text{求和的每一项都取最大})$$

$$= \sum_{j=1}^k \lambda_j \mathbb{E} \left[\sup_{\sigma} \sum_{i=1}^n \sigma_i h_j(x_i) \right] \quad (\text{期望的线性性, } \lambda_j > 0)$$

$$= \sum_{j=1}^k \lambda_j \cdot \hat{R}_{S_n}(\mathcal{H}) = \hat{R}_{S_n}(\mathcal{H})$$

然后, 因为 $R_n(\mathcal{H}) = \mathbb{E} [\hat{R}_{S_n}(\mathcal{H})]$, 在 1. 中应用 "若 $X \leq Y$, 那么 $\mathbb{E}X \leq \mathbb{E}Y$ ".

在 2. 中应用 " $\mathbb{E}[aX] = a\mathbb{E}X$ ", 在 3. 中应用期望的线性性和 1, 即可得到期望 Rademacher 复杂度的如上性质.

□

6.2

对于实轴上的 n 个点, 我们可以从中选择连续的 k 个点, 将其称为正例; 这有


$$\underset{\substack{\uparrow \\ (k=0)}}{1} + \sum_{k=1}^n (n-k+1) = 1 + \frac{n(n+1)}{2}. \quad \text{也即 } \Pi_{\mathcal{H}}(n) = 1 + \frac{n(n+1)}{2}$$

利用 Growth Function Bound, 我们可以得到 $R_n(\mathcal{H}) \leq \sqrt{\frac{2 \log[1 + \frac{n(n+1)}{2}]}{n}}$


6.3

$$1. \text{vcdim}(\mathcal{H}) = 4.$$

下界:




上界: 可以利用几何知识证明 \mathcal{H} 无法打散任一个五边形. 大致思路为:



2. $\text{VCdim}(H) = 2$.


只需考虑三个点的相位 ($\in [0, 2\pi)$)。如果三个点能被标记为 $\{+, +, +\}$ ，我们不妨按相位，将它们排序为 x_1, x_2, x_3 ：

(实际上它们的位置顺序可能不同，这里只是表明它们的相位)。



现在，假设能将 x_1, x_2, x_3 分类为 $\{+, -, +\}$ ，三者相位一定为：

矛盾！ x_3 领先了 x_1 大于 π 的相位。



而 2 个点的情况是容易构造的

